
Llama-3.2-1B
LFM2-1.2B
Qwen3-4B
Gemma3-4B
Llama-3.1-8B
Configuration
S_1
S_2
S_4
TTFT speedup
1.0
1.2
1.4
1.6
†
128
512
2K
8K
32K
Prompt length (tokens)