
Llama-3.2-1B
LFM2-1.2B
Qwen3-4B
Gemma3-4B
Llama-3.1-8B
Split
$S_1$
$S_2$
$S_4$
TTFT speedup
1.00
1.25
1.50
128
256
512
1K
2K
4K
8K
16K
32K
Prompt length (tokens)